

Proyecto I
Optimización Numérica
Programación Cadrática
Clasificación con Separadores Lineales

1 Introducción

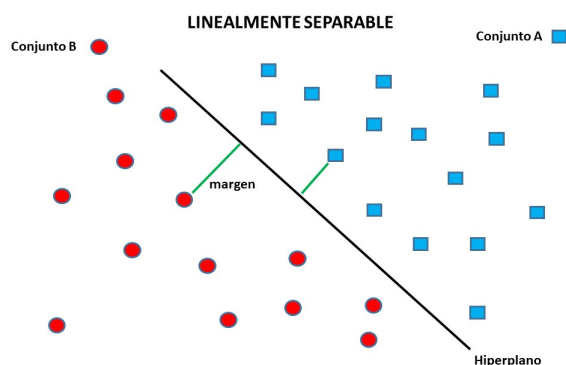
Definición. Decimos que los conjuntos

$\mathbb{A} = \{x_1, x_2, \dots, x_s\}$, $\mathbb{B} = \{x_{s+1}, x_{s+2}, \dots, x_{s+r}\} \subset \mathbb{R}^n$, son **linealmente separables** si y sólo si existe un hiperplano, $\mathcal{H}(w, \beta) = \{x \in \mathbb{R}^n \mid w^T x + \beta = 0\}$, tal que

$$w^T x_i + \beta < 0, \quad \text{para todo } x_i \in \mathbb{A}$$

y

$$w^T x_i + \beta > 0, \quad \text{para todo } x_i \in \mathbb{B}.$$



En diversas aplicaciones se tienen dos conjuntos finitos de vectores como \mathbb{A} y \mathbb{B} que pueden indicar correo spam o no, o puntos en el cuerpo humano indicando células sanas o enfermas. Se necesita conocer si ambos conjuntos son linealmente separables o no. En caso de ser separables, se tiene una clasificación de los datos con el hiperplano $\mathcal{H}(w, \beta)$ y al llegar un nuevo vector y se determina en la zona donde estará el nuevo vector, por ejemplo se clasifica si el nuevo correo electrónico es spam o no.

2 Formulación del Modelo

Sean

$$\mathbb{A} = \{x_1, x_2, \dots, x_s\} \subset \mathbb{R}^n,$$

y

$$\mathbb{B} = \{x_{s+1}, x_{s+2}, \dots, x_{s+r}\} \subset \mathbb{R}^n,$$

para los cuales se debe determinar un hiperplano,

$$\mathcal{H}(w, \beta) = \{x \in \mathbb{R}^n \mid w^T x + \beta = 0\},$$

tal que

$$w^T x_i + \beta < 0, \quad \text{para todo } x_i \in \mathbb{A}$$

y

$$w^T x_i + \beta > 0, \quad \text{para todo } x_i \in \mathbb{B}.$$

Lema. Sea $\mathcal{H}(w, \beta) = \{x \in \mathbb{R}^n \mid w^T x + \beta = 0\}$, donde $w \neq 0$ y $\beta \in \mathbb{R}$. La distancia de y al conjunto \mathcal{H} esta determinada por

$$d(y, \mathcal{H}(w, \beta)) = \frac{|w^T y + \beta|}{\|w\|_2}.$$

El margen de los conjuntos \mathbb{A} , \mathbb{B} y $\mathcal{H}(w, \beta)$ se define como

$$\begin{aligned} \mathbf{Min} \quad & \frac{|w^T x_i + \beta|}{\|w\|_2} \\ & x_i \in \mathbb{A} \cup \mathbb{B}, \end{aligned}$$

El problema sería

$$\begin{aligned} \mathbf{Max} \quad & \left(\mathbf{Min} \left\{ \frac{|w^T x_i + \beta|}{\|w\|_2} \mid x_i \in \mathbb{A} \cup \mathbb{B}, \right\} \right) \\ (w, \beta) \\ \mathbf{Sujeto a} \quad & w^T x_i + \beta < 0, \quad x_i \in \mathbb{A} \\ & w^T x_i + \beta > 0, \quad x_i \in \mathbb{B} \end{aligned}$$

Por escalamiento, podemos pedir que

$$\mathbf{Min}\{|w^T x_i + \beta| \mid x_i \in \mathbb{A} \cup \mathbb{B}\} = 1$$

El problema se convierte

$$\begin{aligned} \mathbf{Max} \quad & \frac{1}{\|w\|_2} \\ (w, \beta) \\ \mathbf{Sujeto a} \quad & \min\{|w^T x_i + \beta| \mid x_i \in \mathbb{A} \cup \mathbb{B}\} = 1 \\ & w^T x_i + \beta < 0, \quad x_i \in \mathbb{A} \\ & w^T x_i + \beta > 0, \quad x_i \in \mathbb{B} \end{aligned}$$

por la primer restricción de desigualdad se obtiene

$$\begin{array}{ll} \text{Max} & \frac{1}{\|w\|_2^2} \\ (w, \beta) & \\ \text{Sujeto a} & \text{Min}\{|w^T x_i + \beta| \mid x_i \in \mathbb{A} \cup \mathbb{B}\} = 1 \\ & w^T x_i + \beta \leq -1, \quad x_i \in \mathbb{A} \\ & w^T x_i + \beta \geq 1, \quad x_i \in \mathbb{B} \end{array}$$

La formulación final del problema es

$$\begin{array}{ll} \text{Min} & (1/2)w^T w \\ (w, \beta) & \\ \text{Sujeto a} & w^T x_i + \beta \leq -1, \quad i = 1, 2, \dots, s \\ & w^T x_i + \beta \geq 1, \quad i = s+1, s+2, \dots, s+r, \end{array}$$

con las variables $w \in \mathbb{R}^n$, $\beta \in \mathbb{R}$.

3 Proyecto

Escriba en Matlab un método de puntos interiores para el problema cuadrático general:

$$\begin{array}{ll} \text{Min} & \mathbf{x}^T \mathbf{Q} \mathbf{x} + \mathbf{c}^T \mathbf{x} \\ \text{Sujeto a} & \mathbf{F} \mathbf{x} \geq \mathbf{d}, \end{array} \quad (1)$$

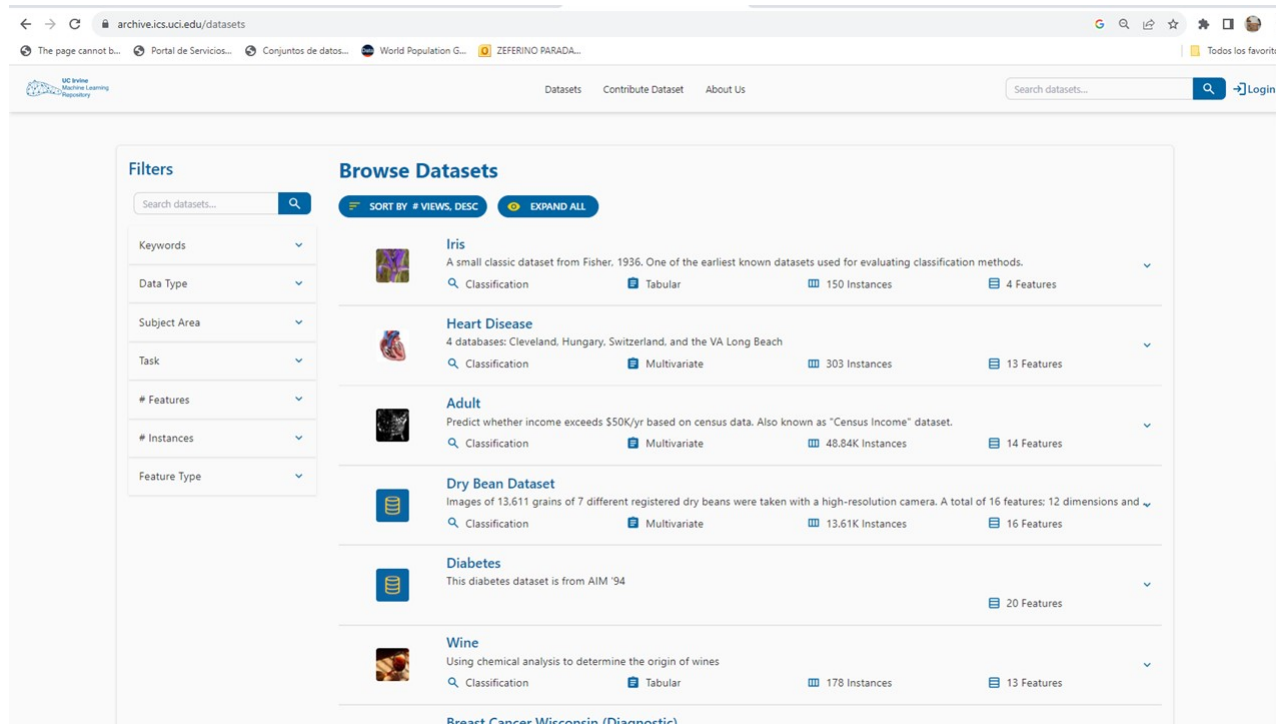
con \mathbf{Q} matriz simétrica positiva definida.

```
function [x, mu, iter] = qpintpoint2(Q, F, c, d)
% x solución óptima del problema.
% mu multiplicador de Lagrange asociado a la restricción Fx ≥ d.
% iter número de iteraciones en el proceso.
% La tolerancia para las condiciones necesarias de primer orden es
% tol = 1e - 05.
% Número máximo de iteraciones es maxiter = 100.
```

4 Datos

Usaremos los datos de la Universidad de California en Irvine:

<https://archive.ics.uci.edu/datasets>



Los datos son de:

1. Iris.
2. Wine.
3. Breast cancer.

Los datos deben estudiarlos y entenderlos, en caso necesario llenar algunas entradas sin dato y pasarlos a un archivo que Matlab pueda interpretar en forma sencilla.

5 Qué Entregar

Equipos de a lo más tres personas.

1. Programa: *qpintpoint2.m*
2. Scrip live file . *separacion.mlx*, donde obtenga los valores de w y β en la pantalla y la graficaciones de: $\mathbb{A}^T w - e$ y $\mathbb{B}^T w - e$. Estas gráficas muestran la separación de los conjuntos con respecto al signo, positivo o negativo, que deben tener los puntos con respecto la hiperplano.
3. Enviar por Canvas la base de datos que usaron.

4. Programas con los nombres y clave única de los integrantes del equipo y documentación de los códigos.
5. Entrega por Canvas, **jueves 12 de octubre de 2023 a las 16:00 horas**.
Una entrega por cada equipo.
6. Presentación: **jueves 12 de octubre de 2023 a las 16:00 horas**

6 Calificación

Concepto	Comentarios y Sugerencias	Ponderación	Calificación
Parte Teórica		20	
Programación		30	
Resultado Numérico		30	
Graficación		10	
Presentación		10	
TOTAL de puntos		100	